

基于边界检测和像素扩张的古建筑语义分割

李 玉 张素兰*

(太原科技大学计算机科学与技术学院 山西 太原 030024)

摘 要 由于古建筑中包含的装饰部分大都依附于建筑上且与建筑本体相比尺寸较小,存在难检测、难分割的问题,提出一种基于边界检测和像素扩张的古建筑图像语义分割方法。利用 VGG 网络对古建筑图像进行特征提取;使用 HED 检测技术对图像进行边界检测,将古建筑中较难检测的装饰部分与建筑本体区分开,生成边界约束。在边界约束区域内,使用像素的八连通特性对古建筑中难分割的部分进行扩张,完成古建筑图像的语义分割。在古建筑图像数据集和 ADE20K 数据集上的实验验证了该方法的有效性。

关键词 古建筑 语义分割 边界检测 像素扩张

中图分类号 TP3 **文献标志码** A **DOI**: 10.3969/j.issn.1000-386x.2025.10.034

SEMANTIC SEGMENTATION OF ANCIENT ARCHITECTURE BASED ON BOUNDARY DETECTION AND PIXEL EXPANSION

Li Yu Zhang Sulan*

(School of Computer Science and Technology, Taiyuan University of Science and Technology, Taiyuan 030024, Shanxi, China)

Abstract In order to solve the problem that the decorative parts contained in ancient buildings are mostly attached to the building and smaller than the building body, which is difficult to detect and segment, a semantic segmentation method of ancient architecture images based on boundary detection and pixel expansion is proposed. The VGG network and HED detection technology were used to extract features of ancient building images and detect the boundary of image respectively so that the decorative parts which were difficult to detect in the ancient building were separated from the building body to generate boundary constraints. Within the boundary constrained area, the eight-connectivity feature was used to achieve the semantic segmentation of the ancient architecture images by expanding the hardly segment parts of ancient architecture. The effectiveness of this method was proved by the experiments based on ancient architecture image dataset and ADE20K dataset.

Keywords Historic building Semantic segmentation Boundary detection Pixel expansion

0 引 言

古建筑图像语义分割的研究有利于人们开展对古建筑的相关工作,例如保护修缮^[1]、三维重建^[2]、数字化复原^[3]等。而且古建筑图像的准确分割可以帮助研究者获取到不同时期建筑风格的特点,便于对其进行分类;也有助于研究者在处理历史文化遗产保护工作时根据不同建筑风格特点制定出相应的保护措施。对

象检测与图像分类是古建筑图像语义分割的两个重要步骤,其中:对象检测可以对图像中的目标对象实现位置标定,图像分类可以将图像中不同类别的目标区域分开。但因古建筑中包含的装饰部分大都依附于建筑上且与建筑本体相比尺寸较小,存在难检测、难分割的问题。

近年来,人们对古建筑图像语义分割方法进行了广泛研究,大致分为两类。第一类方法主要是基于古建筑结构的语义分解,其将建筑中的几何单元基本组

件转化为建筑中存在的语义组件^[4-6]。Li等^[6]根据古建筑的风格特点,利用应用领域扩展机制对故宫博物院的屋顶进行语义分解,并且通过对语义组件的拓扑约束和导出变换,保证分解元素的有效性和多样性。张文元等^[8]使用城市地理标记语言对古建筑的几何模型进行了语义扩展,有效地总结出古建筑典型构件的共有特征。但该类方法主要是对古建筑的部分构件进行分析提取,缺乏对古建筑整体性特征的描述。第二类方法是使用点云数据^[7-10]对古建筑进行分割,其将点云数据按照相似的空间、纹理、几何等特征分类后进行分割。张瑞菊等^[8]根据古建筑的特性对获得的点云数据进行坐标转正,提高了古建筑点云数据分割的自动化程度,减少了人工干预。Crocce等^[9]使用机器学习技术和深度学习技术将获取的三维点云数据进行语义标记,实现原始的、非结构化的传统点云数据向可理解的、语义的3D表示过渡。但通过三维激光扫描技术获取的点云数据在遇到有遮挡物或者角度有偏差时往往噪声较大,且古建筑包含大量的木构件,通过点云数据进行语义分割时其中一些木构件难以被分割。可以看出,无论是使用语义分解的方法还是使用点云数据的方法,都难以将古建筑的整个建筑体和建筑中的部分构件进行完全分割。

在古建筑图像语义分割工作中不仅需要关注整个建筑体的架构,还需关注古建筑中存在的细节。因为这些细节部位往往能反映建筑物所在朝代的文化和其文明程度。然而这些细节部位本身相比建筑本体尺寸较小,在进行分割时难与建筑本体分开,因此,成为古建筑图像分割中一个难点问题。一般地,使用图像级标签进行语义分割时,由于数据集缺乏语义边界的注释,导致图像边界分割不清楚。人们提出使用边界创造伪图像^[11]补充缺失的语义边界,或者通过提取图像的多尺度和多层次信息^[12]以增强边界的特征选择^[13]。对于复杂图像的分类,从像素级别进行损失函数^[14]的设置以及类的最优特征表示^[15],建立像素间的相似性度量。因此,使用图像边界和像素处理是解决古建筑图像细节难分割的一种有效方法。

综上所述,本文提出一种基于边界检测和像素扩张的古建筑图像语义分割方法,以解决古建筑图像中建筑本体与装饰细节部位之间存在的难检测、难分割的问题。本文贡献主要概括如下:

(1) 引入边界检测模块,利用边界检测技术提取古建筑图像不同尺度的层次特征,并将不同尺度信息进行融合,为分割提供了具有判别力的先验知识,明确古建筑本体与装饰细节部分的边界。

(2) 利用像素扩张的方法,计算古建筑图像难分割部分的像素类中心,通过像素的8连通特性,将类别较小的像素通过类中心检测聚合在一起,进一步改进古建筑图像的分割结果。

1 相关工作

1.1 古建筑图像语义分割

古建筑作为中华民族历史的见证,对研究历史文化遗产保护有非常重要的参考价值。以往人们注重对古建筑进行图纸修复、三维重建的工作,而现在分析古建筑图像内容成为一个新的趋势。张瑞菊等^[8]利用古建筑结构布局的特点以及从点云数据中获取的竖直轴向、柱列轴线和构件尺寸等信息,将木构件对应的点云数据自动分割出来,最大限度地减少人工干预。赵海英等^[16]将字典的不相关性与系数相似性结合,提出多标签字典学习标注算法对民族文化图案进行自动标注。Zhou等^[17]提出利用标注图像集微调CNN进行古建筑图像语义分割,将像素标签投影到3D模型中以生成语义3D模型,充分利用三维几何信息,提高了模型标注精度。

1.2 边界检测

图像边界表示某一区域的结束和另一区域的开始,将图像边界引入古建筑的语义分割中,可帮助人们获得更清晰的语义分割结果。Liu等^[12]使用具有丰富卷积特征(RCF)的边缘检测器,利用多尺度^[18-19]和多层次信息,全面地执行对图像的预测。Su等^[13]提出边界定位流增强边界的特征选择性,内部感知流保持内部的特征不变性,同时增加一个过渡补偿流来修正内部和边界之间的过渡区域可能出现的故障。Zhao等^[20]利用显著目标信息与边缘信息的互补性提出了边缘引导网络(EGNet)来进行检测。所以,将边界信息引入到古建筑图像语义分割工作中可以更有效地区分装饰部分与主体部分。

1.3 像素扩张

图像分割是从图像处理到图像分析的关键步骤,为解决图像分割数据集中出现的标注数据短缺的问题,基于像素分割的方法应运而生。Lai等^[14]提出了指令对比损失,以像素对像素的方式实现一致性,要求置信度较低的特征与对应物置信度高的特征对齐。Li等^[15]提出了一个三步伪标记方法:设置最优特征表示算法,利用单个标注像素将每个类分为“对象”或“场景”;然后建立每对像素之间的相似性度量;最后再引入上下文信息和位置先验,逐步实现了对每个类别、图

像推理和基于上下文位置的细化表示。Qi 等^[2]提出了一种新的图像级监督的语义分割框架,使用对象定位分支从分割预测中获得像素标签,实现分类与定位。因此,从像素级别区分图像中的类别对研究古建筑图像语义分割是有必要的。

2 方法介绍

如图 1 所示,本文的语义分割方法主要包括三个部分:特征提取、边界检测、像素扩张。




图 1 基于边界检测和像素扩张的古建筑语义分割模型

2.1 特征提取

使用 VGG-16 作为方法实现的主框架,如图 2 所示。VGG-16 网络包含 5 个卷积块。其中每个卷积层都使用相同的卷积核参数,用两个 3×3 的卷积核代替一个 5×5 的卷积核,不仅可以减少计算量还可以提升网络深度,提高网络性能。由于网络在训练时往往会给特征明显的部分赋予较大权重,在卷积块之间使用不涉及权重的池化层进行分隔可以缓解网络加深时权重差别变大的问题。并且,使用全连接层分类时,可以通过改变全连接层以适应输入的任意古建筑图像尺寸,最后使用 softmax 输出预测结果。




图 2 VGG-16 的网络框图

2.2 边界检测

对于层次结构复杂的古建筑,不同层次的特征都代表着不同程度的建筑文化。为了实现古建筑的多层

次学习,在 VGG-16 网络的每个阶段的最后一个卷积层中添加侧输出层 W ^[2]。如图 3 所示,通过添加侧输出层,对中间的细节进行特征提取,实现多尺度学习。并且对于每个侧输出,使用双线性差值^[23]算法进行上采样,还原到原始图像的尺寸,进一步强化图像的分辨率,通过融合层进行输出。




图 3 边界检测的网络结构

为了解决边缘像素和非边缘像素的不均衡问题,引入类平衡权重 β ,若边缘像素占比较少,则 β 的值比较小。对每一个侧输出层,引入类平衡交叉熵损失函数,如式(1)所示。

$$L_{\text{side}}^{(m)}(W, w^{(m)}) = -\beta \sum_{j \in Y_+} \log \Pr(y_{j=1} | X, W, w^{(m)}) - (1 - \beta) \sum_{j \in Y_-} \log \Pr(y_{j=0} | X, W, w^{(m)}) \quad (1)$$

式中: $|Y_-|$ 和 $|Y_+|$ 分别表示非边缘和边缘地面真值标签集, $\Pr$ 项表示像素 j 上的激活值, W 表示侧输出

层, $W = (w^{(1)}, w^{(2)}, \dots, w^{(m)})$ 。

每个侧输出都会得到一个边缘图预测 $\hat{Y}_{\text{fuse}}$, 加权融合层的损失函数如式(2)所示, 其中: h 为融合权重, Dist 是融合的预测与地面真实标签之间的距离。

$$L_{\text{fuse}}(W, w, h) = \text{Dist}(Y, \hat{Y}_{\text{fuse}}) \quad (2)$$

因此, HED 的输出为 side_branch 和 fuse branch 的均值, 其损失函数如式(3)所示。

$$(W, w, h)^* = \arg \min (L_{\text{side}}(W, w) + L_{\text{fuse}}(W, w, h)) \quad (3)$$

2.3 像素扩张

同一对象的语义标签在边界处仍然具有连续性^[23]。使用边界检测技术, 将像素划分为不同区域, 然后通过边界融合操作, 得到增强的边界图, 并将其转为二值图像, 利用边界像素的 0、1 特性, 将其作为判断扩张与否的基础条件。在划分出的小区域内, 选择已经被识别出来的部分像素作为初始区域, 并将其像素均值作为每个区域的类中心表示。使用像素的 8 连通性检查是否要将目标像素添加到区域内, 并且计算周围像素之间的相似度。重复这个过程, 直至该对象没有符合约束条件的像素为止。像素扩张如算法 1 所示。

算法 1 像素扩张

输入: 边界检测的区域 $R = \{r_1, r_2, \dots, r_n\}$, T 为反映扩张程度的阈值^[24]。

输出: 扩张后的区域 R' 。

1. 在区域 r 中选择扩张像素初始点
2. For $t = 1, 2, \dots, n$ do
3. $\bar{f}_i(x, y) = \frac{1}{9} \sum_{i=x-1}^{i=x+1} \sum_{j=y-1}^{j=y+1} f(i, j)$
4. While $(x_0, y_0) \in r_t$
5. if $f(x_0, y_0) \in r_t$ 且 $f(x_0, y_0) \geq \bar{f}_i(x, y)$
6. (x_0, y_0) 为区域 r_t 的初始点
7. else
8. continue //判断 (x_0, y_0) 的下一个邻接点
9. $m = \frac{1}{k} \sum_{(a,b) \in r_t} f(a, b)$ //在区域 r_t 内将要判断的
//像素点与已经合并的 k 个像素均值 m 作比较
10. if $|f(x, y) - m| \leq T$
11. 则对该像素进行扩张
12. end While
13. End For

3 实验

3.1 数据集

本文使用中国科学院自动化研究所模式识别国家重点实验室提供的古建筑数据集(<http://vision.ia.ac.cn/data>) 和 ADE20K (<http://sceneparsing.csail.mit.edu/>) 数据集来进行评估实验。

古建筑数据集: 为中国四大佛教名山(五台、峨眉、九华、普陀)和两大道教名山(武当、青城)的古建筑图像数据。其中包含着不同的建筑特征与建筑装饰, 例如青城山上清宫前的石狮子雕塑、普陀上法雨禅寺的香炉、屋顶的翘角飞檐等。

ADE20K: 该数据集是一个新的场景解析基准测试, 包含 20 210 幅用于训练的图像、2 000 幅用于验证的图像和 3 352 幅用于测试的图像。在这个数据集中总共有 150 个标签, 包括 35 个东西概念和 115 个离散对象。标签的不平衡分布和图像的不同尺度使数据集更具挑战性。

3.2 实验细节

实验通过 PyTorch 1.4.1 和 Python 3.6 来训练和测试本文方法。实验设备配备了 Core i7-8750H CPU、32 GB RAM 和 NVIDIA GeForce GTX 2080 GPU。所有的模型都采用相同的优化方案进行训练。在训练阶段, 初始化的学习率为 0.01, 权重衰减为 1×10^{-4} , 动量为 0.9。批处理大小为 20, 并使用随机梯度下降(SGD)进行优化。所有的模型都经过了 10 000 次迭代的训练, 每 100 次迭代记录一次测试精度。

3.3 评价指标

本文使用的评价指标是平均交并比(Mean Intersection over Union, MIOU)和像素精度(Pixel Accuracy, PA), 分别如式(4)、式(5)所示。若 MIOU 和 PA 的值越高, 则表示分割的效果越好。

$$P_A = \frac{\sum_{i=0}^k p_{ii}}{\sum_{i=0}^k \sum_{j=0}^k p_{ij}} \quad (4)$$

$$M_{\text{IOU}} = \frac{1}{k+1} \sum_{i=0}^k \frac{p_{ij}}{\sum_{j=0}^k p_{ij} + \sum_{j=0}^k p_{ji} - p_{ii}} \quad (5)$$

式中: p_{ii} 表示 true-positives, p_{ij} 表示 false-positives, $\sum_{j=0}^k p_{ij}$ 表示同属一类却被预测为不同类的像素点数, $\sum_{j=0}^k p_{ji}$ 表示不同类被预测为同一类的像素点数。

3.4 消融实验与分析

为验证本文方法的有效性, 在古建筑数据集与 ADE20K 上进行消融实验。如表 1 所示, 使用基线网络对古建筑图像数据集进行分割时, 分割精度为 72.56%, 由于 ADE20K 数据集相比古建筑数据集比较简单, 所以 ADE20K 数据集上的分割精度要比古建筑数据集的

精度高 0.92 百分点。同时,在使用基线网络与边界检测方法对层次丰富的古建筑图像进行分割时,分割性能可提升 6.06 百分点,这证明物体边界所带来的先验信息对古建筑语义分割是有帮助的,而且 ADE20K 数据集中室内环境较多,通过边界检测技术区分每个类别,其精度可提升 6.84 百分点。在使用基线网络与像素扩张方法对古建筑数据集和 ADE20K 进行分割时,分割性能分别提升 1.33 百分点和 1.78 百分点,这说明通过类中心进行像素 8 连通扩张的方法对语义分割是有效的。当同时将边界区域划分与通过类中心进行像素 8 连通扩张的方法结合起来,古建筑数据集和 ADE20K 数据集的分割精度可达到 79.8% 和 82.19%。

表 1 本文方法的消融实验结果(%)

Baseline	边界检测	像素扩张	古建筑	ADE20K
√	×	×	72.56	73.48
√	√	×	78.62	80.32
√	×	√	73.83	75.26
√	√	√	79.80	82.19

如图 4 所示,通过使用边界检测技术,一些细节和物体的边界更加清晰,如图 4(a) 为普陀山法雨禅寺的侧面图,这两幅图分别对屋脊的边界和上方的标识有不一样的呈现。图 4(b)、图 4(c) 两幅图为九华山旃檀寺的侧面以及正面,分别对装饰雕塑、门中牌匾、屋脊有明显的识别。图 4(d)、图 4(e) 两幅图为青城山上清宫的两幅图,图 4(d) 虽然角度不是很好,但是依然能对门上牌匾进行模糊的识别。图 4(e) 能对屋顶的尖角以及树旁边的石头这些相对比较小的物体的识别。图 4 可以说明使用边界检测和像素扩张不仅能够对整个建筑的分割有帮助,也有助于对古建筑上的牌匾、石柱等进行识别与分割。




图 4 边界检测结果

3.5 不同分割算法在 ADE20K 上的性能比较

为了更好地验证本文方法的有效性,与 FCN^[25]、SedNet^[24]、DilatedNet^[27]、CascadeNet^[28]、RefineNet^[29]、FCN + MCIBI^[30]、EncNet^[31]、CPNet^[32]、Auto-DeepLab^[33] 在 ADE20K 数据集上进行了比较。

如图 5 所示,本文方法在与 FCN^[25]、CascadeNet^[28]、CPNet^[32]、Auto-DeepLab^[33] 等方法作比较时精度略高。其中,CPNet^[32] 方法中通过构造上下文先验与监督的亲和力损失来区分内与类间上下文,但上下文先验知识容易受到场景理解的干扰。由此看出通过多尺度边界融合的方法来划分古建筑的边界的方法是可行的。而如图 6 所示,本文方法在与 RefineNet^[29]、FCN + MCIBI^[30]、EncNet^[31] 这些方法比较平均交并比时相差不大,CPNet^[32] 的分割精度虽然比较低,但是该方法将类别间的上下文建模为先验知识,能够获得更准确的分类信息,所以该方法的平均交并比是比较高的。




图 5 在 ADE20K 数据集上的精度比较




图 6 在 ADE20K 数据集上的 MIoU 的比较

3.6 计算时间

运行 2 000 幅大小为 683 × 512 的 ADE20K 数据集中的图片,训练网络时长 352 s。更准确地说特征提取需要 180 s,边界检测需要 72 s,像素扩张需要 100 s。整个模型的计算时间主要为特征提取和像素扩张占用的时间。由于像素扩张中的扩张区域确定与特征提取的效果相关,所以可以通过将类特征提取最好的结果

记录并保存,随时调用,以此来加快像素扩张的速度,提升模型的性能。

3.7 可视化结果分析

由图 7 展示可知,图 7(a) 为一组木建筑,从分割图中可以看出该建筑的造型特点:屋脊两端的装饰物简单且屋顶舒展平远,符合唐朝建筑的特征。图 7(b) 的建筑分割图相比较图 7(a) 来说,可以观察到屋顶的翼角微起。而在由唐朝发展到宋朝时期人们认为翼角起翘有利于屋面排水、承重、采光等,所以才有了翼角翘起之势。图 7(c) 分割图可以明显看出翼角的坡度向上且由柔和逐渐陡峭,明清时期作为我国古建筑发展的最后一个阶段,其间翼角高翘又慢慢趋于平稳。图 7(d) 展示了对古建筑上的脊兽分割结果,脊兽设计的数目与种类有严格的等级意义。图 8 展示了同一建筑的不同角度的分割可视化结果,可以看出,对同一场景进行分割,不同角度可以分割出古建筑中的部分小部件,例如牌匾、柱子、雕塑等。




图 7 不同朝代的建筑特征分析




图 8 同一建筑不同角度的分割展示

4 结 语

本文提出并实现一种基于边界检测和像素扩张的古建筑图像语义分割方法。通过边界检测方法提取古建筑图像不同尺度的特征,为分割提供了具有判别力的先验知识,使用像素的 8 连通特性对古建筑中难分割部分进行像素扩张,实现古建筑图像语义分割。最后,通过实验验证了本文方法的有效性。未来的工作将集中对古建筑上的小目标分割进行研究。

参 考 文 献

- [1] Gao X, Cui H N, Zhu L J, et al. Multi-source data-based 3D digital preservation of large-scale ancient Chinese architecture: A case report [J]. Virtual Reality & Intelligent Hardware, 2019, 1(5): 525–541.
- [2] Yong L, Xu C F, Zhang Q, et al. Ontology based semantic modeling for Chinese ancient architectures [J]. // 21st National Conference on Artificial Intelligence, 2006: 1808–1813.
- [3] Gao X, Shen S H, Zhou Y, et al. Ancient Chinese architecture 3D preservation by merging ground and aerial point clouds [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2018, 143: 72–84.
- [4] Liu Y, Xu C F, Pan Z G, et al. Semantic modeling for ancient architecture of digital heritage [J]. Computers & Graphics, 2006, 30(5): 800–814.
- [5] Li L, Lei T, Zhu H, et al. Semantic 3D modeling based on CityGML for ancient Chinese-style architectural roofs of digital heritage [J]. International Journal of Geo-Information, 2017, 6(5): 132.
- [6] 张文元, 刘润桦, 万君璧, 等. 基于 CityGML 的明清古建筑三维语义模型扩展及转换研究 [J]. 地球信息科学学报, 2022, 24(2): 326–338.
- [7] Wang Y, Sun Y S, Liu Z W, et al. Dynamic graph CNN for learning on point clouds [J]. ACM Transactions on Graphics, 2019, 38(5): 1–12.
- [8] 张瑞菊, 周欣, 赵江洪, 等. 一种古建筑点云数据的语义分割算法 [J]. 武汉大学学报(信息科学版), 2020, 45(5): 753–759.
- [9] Croce V, Caroti G, Luca L D, et al. From the semantic point cloud to heritage-building information modeling: A semiautomatic approach exploiting machine learning [J]. Remote Sensing, 2021, 13(3): 461.
- [10] Bacci G, Bertolini F, Bevilacqua M, et al. HBIM methodologies for the architectural restoration [J]. Remote Sensing, 2019, 42: 121–126.

- [1] Lu W X, Gong D, Fu K, et al. BoundaryMix: Generating pseudo-training images for improving segmentation with scribble annotations [J]. Pattern Recognition, 2021(2): 107924.
- [2] Liu Y, Cheng M, Hu X W, et al. Richer convolutional features for edge detection [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3000 – 3009.
- [3] Su J M, Li J, Zhang Y, et al. Selectivity or invariance: Boundary-aware salient object detection [C] //IEEE International Conference on Computer Vision, 2019: 3799 – 3808.
- [4] Lai X, Tian Z T, Jiang L, et al. Semi-supervised semantic segmentation with directional context-aware consistency [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2021: 1205 – 1214.
- [5] Li X, Ma H M, Yi S, et al. Single annotated pixel based weakly supervised semantic segmentation under driving scenes [J]. Pattern Recognition, 2021, 116: 107979.
- [6] 赵海英, 陈洪, 贾耕云, 等. 基于字典学习的民族文化图案语义标注 [J]. 中国科学(信息科学), 2019(2): 172 – 187.
- [7] Zhou Y, Shen S H, Hu Z Y. Fine-level semantic labeling of large-scale 3D model by active learning [C] //International Conference on 3D Vision, 2018: 523 – 532.
- [8] 商建东, 刘艳青, 高需. 多尺度特征提取的道路场景语义分割 [J]. 计算机应用与软件, 2021, 38(11): 174 – 178.
- [9] 王彤, 杨秋菊. 结合多类特征融合与 ICM 目标函数优化的图像语义分割方法 [J]. 计算机应用与软件, 2021, 38(8): 240 – 247.
- [10] Zhao J X, Liu J, Fan D P, et al. EGNNet: Edge guidance network for salient object detection [C] //IEEE International Conference on Computer Vision, 2019: 8779 – 8788.
- [11] Qi X J, Liu Z, Shi J P, et al. Augmented feedback in semantic segmentation under image level supervision [C] //European Conference on Computer Vision, 2016: 90 – 105.
- [12] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [EB]. arXiv: 1409.1556, 2014.
- [13] Huang Z L, Wang X G, Wang J S, et al. Weakly-supervised semantic segmentation network with deep seeded region growing [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7014 – 7023.
- [14] 张玲, 郭磊民, 何伟, 等. 一种基于最大类间方差和区域生长的图像分割法 [J]. 信息与电子工程, 2005, 3(2): 91 – 93.
- [15] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3431 – 3440.
- [16] Badrinarayanan V, Kendall A, Cipolla R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481 – 2495.
- [17] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions [EB]. arXiv: 1511.07122, 2015.
- [18] Zhou B, Zhao H, Puig X, et al. Scene parsing through ADE20K dataset [C] //IEEE Conference On Computer Vision and Pattern Recognition, 2017: 633 – 641.
- [19] Lin G S, Milan A, Shen C H, et al. RefineNet: Multi-path refinement networks for high-resolution semantic segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1925 – 1934.
- [20] Jin Z C, Gong T, Yu D, et al. Mining contextual information beyond image for semantic segmentation [C] //IEEE International Conference on Computer Vision, 2021: 7231 – 7241.
- [21] Zhang H, Dana K, Shi J P, et al. Context encoding for semantic segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7151 – 7160.
- [22] Yu C Q, Wang J B, Gao C X, et al. Context prior for scene segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2020: 12416 – 12425.
- [23] Liu C X, Chen L C, Schroff F, et al. Auto-DeepLab: Hierarchical neural architecture search for semantic image segmentation [C] //IEEE Conference on Computer Vision and Pattern Recognition, 2019: 82 – 92.
- ~~~~~
- (上接第 213 页)
- [2] 何斌, 张亦博, 龚健林, 等. 基于改进 YOLO v5 的夜间温室番茄果实快速识别 [J]. 农业机械学报, 2022, 53(5): 201 – 208.
- [3] 熊正午, 吴瑞梅, 黄俊仕, 等. 深度学习结合快速导向滤波识别自然环境下脐橙果实 [J]. 江西农业大学学报, 2022, 44(3): 736 – 746.
- [4] Gill H S, Khalaf O I, Alotaibi Y, et al. Multi-model CNN-RNN-LSTM based fruit recognition and classification [J]. Intelligent Automation & Soft Computing, 2022, 33(1): 637 – 650.
- [5] 张继成, 李德顺. 基于深度残差学习的成熟草莓识别方法 [J]. 中国农机化学报, 2022, 43(2): 136 – 142.
- [6] 郭延华, 孙磊, 马世超, 等. 一种基于极端尺度变化的船舶识别方法研究 [J]. 计算机应用与软件, 2021, 38(1): 171 – 178.
- [7] 高宗斌, 崔永杰, 李凯. 基于 T-YOLO-LITE 树干检测的模型部署方法 [J]. 计算机应用与软件, 2021, 38(2): 132 – 139.
- [8] 褚文杰. 基于 YOLOv5 的坦克装甲车辆目标检测关键技术的研究 [D]. 北京: 北京交通大学, 2021.